

Auditoría del manuscrito ENVIO_CAN2026

Revisión adversarial por cuatro revisores independientes

Neurology · Alzheimer's & Dementia · The Lancet / Lancet Regional Health – Americas · Nature

Fecha: 9 de agosto de 2026 **Objeto:** manuscrito/ENVIO_CAN2026_v2.md y los bloques de análisis V25 a V28 **Encargo:** Fernando Márquez

Cómo se hizo esta auditoría

Se encargó a cuatro revisores independientes, cada uno con el perfil y los estándares de una revista distinta, una revisión **adversarial**: la consigna explícita fue encontrar lo que falla, no validar. Cada uno recibió el manuscrito completo, el material suplementario, las salidas numéricas en JSON y **el código fuente de los análisis**, con instrucción de leer el código y no sólo los resultados. Ninguno vio la revisión de los otros.

Las objeciones cuantificables **se verificaron una por una** antes de aceptarlas, corriendo el código correspondiente. El resultado de esa verificación abre este documento, porque cambia el peso que hay que dar a cada objeción: algunas se confirmaron y obligaron a rehacer análisis; otras se sostienen como juicio pero no como error demostrable.

Advertencia de lectura. Este documento reproduce las cuatro revisiones tal como fueron emitidas, incluidas las afirmaciones que la verificación posterior matizó o no pudo confirmar. Donde eso ocurre se señala en el cuerpo. Se conserva el texto original porque el valor de una auditoría está en lo que dijo, no en lo que resistió.

Resumen ejecutivo

Recuento de objeciones

Revisor	Fatales	Mayores	Moderadas	Menores	Recomendación
Neurology	4	15	12	8	Rechazo con invitación a reenviar
Alzheimer's & Dementia	3	10	6	4	Rechazo (no «con invitación»)
Lancet	3	11	10	5	Reorientar el mensaje
Nature	4	7	6	6	Rechazo para el grupo Nature

En qué convergen los cuatro, sin haberse consultado

1. El grupo control es el punto de quiebre. Los cuatro llegaron por caminos distintos a la misma conclusión: todo lo que depende del grupo control —el gradiente de 33,4 puntos porcentuales, la comparación de reglas, la afirmación de equidad— no está identificado. El bloque V19 del propio repositorio muestra que los 342 controles rinden entre $-1,3$ y $-2,7$ desvíos en pruebas que **no** forman parte del criterio, con normas ya ajustadas por educación, y que sólo el **4,1** % de los controles con menos de 7 años de escolaridad no tiene ninguna prueba baja, frente al **28,7** % de los de 12 o más.

2. El criterio de control se eligió por el procedimiento equivocado. Se adoptó el peldaño con el valor p más alto de una escalera de seis candidatos ($p = 0,041 \cdot 0,000 \cdot 0,215 \cdot \mathbf{0,504} \cdot 0,025 \cdot 0,0002$). Seleccionar sobre la no significación no acredita independencia. Y la condición impuesta —igualdad de **tasas de aceptación**— no es la correcta: lo sería la igualdad de **sensibilidad al deterioro**, y como la prevalencia verdadera sí difiere por escolaridad, forzar tasas iguales **obliga** a que el grupo de menor escolaridad esté más contaminado, justo en la dirección que infla el gradiente.

3. El bloque V26 contenía errores demostrables. Tres revisores independientes señalaron el signo invertido de la desatenuación; dos, el carácter tautológico de la «predicción falsable»; dos, la no identificación de la métrica latente. **Los tres se verificaron y se confirmaron.**

4. Lo que sobrevive intacto. Los cuatro coinciden, y lo consignan explícitamente:

- La **reconstrucción documental** de la procedencia del 86 y del 68, y la constatación de que el umbral de los 12 años no aparece en ninguna fuente primaria. Es el mejor aporte del trabajo y no depende de ningún supuesto estadístico.
- La **forma funcional** curvilínea, replicada en dos cohortes de selección opuesta y ahora también en un segundo instrumento.
- La **falsación de la discontinuidad** con prueba de equivalencia y placebo sobre los catorce cortes. Tres revisores la califican de aporte metodológico genuino, y destacan que detecte el artefacto de amontonamiento en 7 años como prueba de que el procedimiento discrimina.
- La **ausencia de sesgo de medición por ítem**, que mata limpiamente la explicación «los ítems están sesgados».

Verificación de las objeciones cuantificables

Antes de reproducir las revisiones, el resultado de comprobar sus afirmaciones contra el código.

Confirmadas

El signo de la desatenuación estaba invertido

V26_dispersion_metrica_latente.py calculaba $\text{var_verdadera} = \text{var}(\hat{\theta}) - E[SE^2]$. Para un estimador de media posterior la ley de la varianza total da lo contrario:

$$\text{Var}(\theta) = \text{Var}(E[\theta|X]) + E[\text{Var}(\theta|X)] = \text{Var}(\hat{\theta}_{\text{EAP}}) + E[SE^2]$$

Comprobación decisiva:

Cantidad	Valor
$\text{Var}(\text{EAP})$	0,9090
$E[SE^2]$	0,0746
$\text{Var}(\text{EAP}) + E[SE^2]$	0,9836 ≈ 1 , la varianza de la previa
$\text{Var}(\text{EAP}) - E[SE^2]$	0,8344, incompatible con el propio modelo

La serie publicada $0,697 \cdot 0,395 \cdot 0,533$ era incorrecta. **Objeción confirmada.**

El bootstrap de la varianza verdadera estaba dominado por el recorte

La pendiente se estimaba sobre $\log(\text{clip}(r^2 - SE^2, 1e-6))$. Verificado: **140 de 342 observaciones (40,9 %)** caen en el recorte y reciben $\log(1e-6) = -13,82$ como variable dependiente. La cifra publicada carecía de interpretación. **Objeción confirmada.**

La «predicción falsable» no era falsable

La relación *desvío del puntaje* $\approx$ *pendiente local* $\times$ *desvío de habilidad* es la identidad del método delta de primer orden. El revisor de Nature la simuló bajo cuatro escenarios sustantivamente opuestos:

Escenario (dispersión verdadera de habilidad)	Razón tramo 1	2	3
A · como en el paper (0,74 / 0,47 / 0,61)	0,96	0,92	0,90
B · exactamente constante (0,60 / 0,60 / 0,60)	0,95	0,92	0,90
C · compresión en las personas (1,00 / 0,70 / 0,40)	0,99	0,92	0,94
D · compresión inversa (0,40 / 0,70 / 1,00)	0,93	0,92	0,80

Las razones son indistinguibles entre el escenario que el manuscrito afirmaba y su negación exacta. **Objeción confirmada, y concedida sin reservas: fue un error de encuadre.**

La partición entre escala y personas no está identificada

Un modelo de respuesta al ítem identifica la habilidad sólo hasta transformación monótona. Verificado sobre el mismo modelo ajustado:

Métrica	Por el instrumento	Por la habilidad
θ , previa normal (la que usaba el manuscrito)	1,59×	1,22×
$\tau = E[ACE \theta]$, puntaje verdadero de Lord	1,00×	1,74×

Mismo modelo, mismos datos, conclusión opuesta. **Objeción confirmada.**

La comparación del IFS entre cohortes no es válida

El propio material suplementario, bloque V12, documenta: «*Las series motoras se descartaron por escalas distintas entre bases (máximo 3 frente a 6)*». Las series motoras son el subtest 1 del IFS, de modo que los totales de las dos bases no están en la misma escala. **Objeción confirmada.** Invalida la forma funcional, la replicación de curvatura, la discontinuidad y el placebo del bloque V27; no invalida lo que usa una sola base.

El perfil del grupo control, y una frase codificada

V19_perfil_controles.json confirma los z negativos en toda la batería, y la frase interpretativa que afirma lo contrario —«los tres tramos se ubican en rango y sin diferencias sistemáticas»— **está codificada como cadena literal** en la línea 144 del script, no derivada de los resultados. **Objeción confirmada.**

No verificadas

- Que las cifras de contaminación **60,7 % y 48,9 %** no existan en ningún archivo del repositorio: la búsqueda por subcadena devolvió coincidencias que pueden ser espurias. **Requiere comprobación dirigida.**

- Las objeciones sobre gobernanza de datos de ReDLat, interpretación normativa y estructura del trabajo son juicios editoriales, no errores demostrables.

Corregido tras la verificación

El bloque V26 se rehízo: se eliminó la desatenuación escalar y el bootstrap defectuoso, se sustituyeron por un **GRM multigrupo con media y varianza latentes libres por tramo** —que no usa el EAP y no arrastra su contracción—, se incorporó el Levene sobre θ , y se declaró explícitamente la no identificación de la métrica.

Tramo	n	Media latente	DE latente
menos de 7 años	74	−0,555	0,732
7 a 11	118	−0,062	0,411
12 o más	150	+0,687	0,598

Razón entre extremos **1,22x** frente a **1,74x** en el puntaje bruto, con patrón **no monótono**.

Revisor 1 – *Neurology*

Perfil: exactitud diagnóstica y clasificación de evidencia (AAN).

Nota operativa previa del revisor: el manuscrito no contiene ninguna mención al IFS, al MMSE ni a ReDLat. V27/V27b/V28 no están incorporados y tampoco figuran en CIFRAS_MAESTRAS.json. La revisión los trata como material candidato.

FATAL

F1. La desatenuación del error de medición tiene el signo invertido. Para un estimador bayesiano de media posterior la ley de la varianza total da **var verdadera = var(EAP) + E[SE²]**. El EAP ya está contraído; restarle otra vez el error descuenta la contracción dos veces. Con el signo corregido las DE pasan de $0,697 \cdot 0,395 \cdot 0,533$ a **$0,784 \cdot 0,538 \cdot 0,677$** , y la razón entre extremos de 1,31 a **1,16**. *Qué pediría:* GRM multigrupo con medias y varianzas latentes libres por tramo, o valores plausibles.

F2. «Sobre la habilidad latente desaparece» es no-significación presentada como ausencia. Tres problemas, cada uno suficiente: (a) el límite inferior del intervalo, $-0,0454$, implica conservar hasta el **55 %** de la pendiente bruta; (b) el propio V26 **rechaza la homocedasticidad en θ** (Levene $W = 8,157$, $p = 3,5 \times 10^{-4}$) y eso no aparece en el manuscrito; (c) el nulo es un artefacto de forma: una pendiente lineal sobre una función en U es ≈ 0 por construcción.

F3. El bootstrap de la pendiente de la varianza verdadera está mal especificado. Aproximadamente el 40 % de las observaciones reciben $\log(1e-6) = -13,8$. El resultado publicado carece de interpretación.

F4. «Lo produce la escala» no es contrastable con un GRM unidimensional. La escala θ es la que hace normal a la población de calibración, por definición de la previa. Con **$r(\theta, \text{bruto}) = 0,98$** , θ es un reetiquetado no lineal del mismo puntaje. Y la «predicción falsable» es la identidad del método delta: **se cumple necesariamente**.

MAYOR

M1. El estrechamiento bruto observado no es monótono ($14,3 / 8,1 / 8,2$) y el « $13,2 \rightarrow 5,8$ » es extrapolación fuera del soporte: la escolaridad media del tramo bajo es 4,1 años y la del alto 14,7.

M2. Las DE por tramo son incondicionales: el Levene compara cantidades que contienen la varianza *entre* niveles educativos dentro de cada banda. Debe repetirse sobre residuos del modelo de posición.

M3. El grupo «sin deterioro» admite el 72 % de los DCL clínicos, con contaminación diferencial (60,7 % frente a 48,9 %). Y los controles de ≥ 12 años puntúan **3,27 DE por debajo** de los controles normativos publicados con escolaridad equivalente.

M4. El criterio de control se eligió maximizando un p de no significación (0,504 entre seis candidatos). No acredita independencia; garantiza un p inflado.

M5. El IC de los 33,4 pp corresponde a un estadístico máx – mín seleccionado, que **no puede cubrir el cero**. Debe informarse el contraste preespecificado.

M6. El bootstrap de equidad no propaga la incertidumbre del modelo normativo ni del emparejamiento: el IC del Δ Youden **está subestimado**.

M7. «Sin costo demostrable» es una afirmación de no inferioridad sin margen preespecificado, y el punto estimado **no es estable**: el Δ Youden va de $-0,023$ a $+0,039$ según la definición de control.

M8. El sesgo bidireccional que se compensa es **la firma de multidimensionalidad**, no de ausencia de sesgo. La cancelación es una propiedad de esta mezcla de ítems, no de equidad. Y la evidencia de dimensionalidad es débil: primer factor 35,8 % de la varianza, tres autovalores > 1 , Q3 máximo 0,348.

M9. El DTF continuo, significativo y mayor, no se informa: **$-0,07$ por año, $p = 4,8 \times 10^{-6}$** , $\approx 1,2$ puntos sobre el rango, frente a los 0,34 del contraste dicotómico que sí se publica. Reporte selectivo.

M10. El GRM se calibra sobre 2785 casos, **72,8 % clínicos**, y el θ resultante se usa sólo sobre 342 controles comunitarios, pese a que la Limitación octava reconoce que tres ítems no son invariantes entre cohortes.

M11. El colapso de categorías, guiado por los datos, fija la curva característica de la que sale todo el mecanismo. La TCC reconstruida **no alcanza el techo** que el argumento invoca.

M12. La afirmación de mejor detección en el tramo intermedio descansa en **cuatro pacientes** (54/63 frente a 58/63), sin IC ni McNemar. Y la frase sobre los once casos no detectados afirma una intersección que las propias cifras excluyen.

M13. Multiplicidad: el control por familia cubre sólo la discontinuidad. La equivalencia a **± 3 no sobrevive Bonferroni** sobre las seis pruebas declaradas.

M14. El extremo del salto descansa en dieciséis personas: el IC exacto de $1/16$ va de 0,2 % a 30 %.

M15. La dispersión **no está entre los objetivos declarados** y no tiene clase de evidencia asignada, pese a ser la segunda cláusula del título. Y se declara STARD sin diagrama de flujo, cegamiento ni tratamiento de indeterminados.

MODERADA (selección)

Dos valores distintos para la misma cantidad (1,22 en el texto, 1,31 implícito en el pie de figura) · el $p = 0,051$ atribuido a la comparación equivocada · la descomposición no cierra ($1,595 \times 1,218 = 1,94$ frente a 1,745 observado) · las razones predicha/observada tienen deriva sistemática y el criterio de éxito está fijado dentro de un print · «cerca del techo» no describe los datos: sólo el 2,7 % del tramo alto está a ≤ 3 puntos del techo · el EEM se informa sin su intervalo, que va de 1,5 a 9,3 EEM por escalón · $p = 0,764$ atribuido al contraste equivocado · V28 se contradice consigo mismo · V28 excluye los 42 sujetos con $CDR = 0,5$, que es sesgo de espectro · V28 declara el estrato inestimable y luego lo usa · V27b correlaciona sobre cinco puntos, tres del mismo estudio · el «gradiente» por corte del IFS está saturado.

Lo que el revisor consigna como inusualmente bien hecho

La reconstrucción documental · la prueba de placebo sobre los catorce cortes · declarar que la planitud de la corrección continua es una identidad algebraica y no un hallazgo · la corrección de Harvey implementada con el signo correcto y verificada empíricamente · la escalera de definiciones de control de V22, que muestra robustez genuina y **no está en el manuscrito** · el bloque A de V28, que declara la infactibilidad del estrato de baja escolaridad *antes* de mirar los resultados: «conducta ejemplar».

Revisor 2 — Alzheimer's & Dementia

Perfil: *psicometría, normas neuropsicológicas y equidad diagnóstica en Latinoamérica.*

Recomendación: rechazo. No «rechazo con invitación»: la objeción 1 de la revisión previa no fue resuelta, y la evidencia generada desde entonces por el propio equipo **la agrava**.

FATAL 1 — El criterio de control se eligió maximizando un p de no-asociación, que es la condición equivocada

Peldaño	n	p (χ^2 control x tramo)	gradiente
1. reconocimiento ≥ 10	663	0,041	44,0 pp
2. + sin ACV	508	0,000	34,4 pp
3. + ...	366	0,215	35,0 pp
4. el publicado	342	0,504	33,4 pp
5. + ...	172	0,025	41,8 pp
6. + ...	128	0,0002	40,5 pp

Y el p de 0,504 **se recupera agregando** el criterio «sin traumatismo de cráneo», que excluye a 154 personas. El componente `func_adlq_basica` está marcado "admitido": false en V18 ($p_{\text{edu}} = 0,0176$) **y sin embargo integra el criterio final**.

El punto central: «igual tasa de aceptación» y «igual sensibilidad al deterioro» sólo coinciden si la prevalencia verdadera es independiente de la escolaridad. **El propio manuscrito afirma lo contrario** (10,7 % frente a 21,4 % sin educación formal). Forzar tasas iguales **obliga** a que el grupo control de baja escolaridad esté más contaminado.

Mecanismo verificable: el criterio usa aciertos crudos de reconocimiento sin corregir falsos positivos. Entre quienes lo pasan, el **reconocimiento corregido** tiene $z = -2,55 \cdot -1,28 \cdot -0,46$ ($p < 0,001$). La neutralidad educativa celebrada **es un artefacto del sesgo de respuesta**.

FATAL 2 — El grupo control no se ve normal en ninguna prueba, y el archivo que lo demuestra no se envía

Prueba	$z < 7$	7-11	≥ 12	% con $z < -1,5$
Trail Making A	-2,73	-2,07	-0,68	43,0 %
Rey · reconocimiento corregido	-2,55	-1,28	-0,46	31,0 %
Trail Making B	-1,96	-2,10	-0,62	35,4 %
Rey · recuerdo inmediato	-1,62	-1,67	-0,76	38,6 %
Dígitos directos	-1,32	-1,29	-0,78	46,8 %

Sin ninguna prueba bajo $-1,5$ z : **4,1 % · 2,5 % · 28,7 %** ($p < 0,001$).

Estar 2,7 desvíos por debajo de una norma **que ya corrige por escolaridad** no es «rendir conforme a lo esperado»: es deterioro. Y el texto interpretativo que afirma lo contrario **está codificado como cadena literal** en el script. El material no figura en el suplementario enviado.

FATAL 3 — La defensa cuantitativa del gradiente descansa en seis personas

El «35 % de contaminación» sale de la definición «D4 todo», con $n = 87$ controles y **6 en el tramo de menos de 7 años**. Esa definición tiene $p_{\text{edu}} = 0,000$, es decir, es una de las que el propio criterio declarado descarta. Y las cifras **60,7 % y 48,9 % no aparecen en ningún archivo del repositorio**, violando la regla que el propio proyecto estampa en CIFRAS_MAESTRAS.j son . *(Esta última afirmación no pudo verificarse de forma concluyente; ver la sección de verificación.)*

MAYOR (síntesis)

4. El intervalo de la pendiente latente traducido a razón de desvíos es **[0,58 · 1,58]**: los datos son compatibles con un estrechamiento de hasta 1,58, más de lo que el manuscrito reporta como observado. **5.** El signo invertido del EAP, con la tabla de valores correctos, y la incoherencia entre el 1,22 del texto y el 1,31 del pie de figura. **6.** La métrica θ no está identificada y la «predicción falsable» es una identidad; la calibración mezcla dos poblaciones que el propio V4-F declara no invariantes. **7.** V26 esconde que sobre θ la dispersión **sí** es heterogénea, y no contrasta la hipótesis alternativa —contaminación diferencial— que predice los mismos datos. **8.** Las cifras titulares son extrapolación fuera del soporte. **9. La comparación ACE-III / IFS no es legítima:** el suplementario documenta escalas distintas entre bases para las series motoras; además $\max(\text{bruto})$ resuelve duplicados por el máximo y no existe bloque de armonización análogo al del ACE-III. **10.** Un corte que señala al 88 % del propio grupo control, sobre una muestra 3,27 DE por debajo de la norma, no permite leer los percentiles como evidencia de inequidad. **11.** V28 no aporta: el AUC de 0,948 no cuantifica nada del ACE-III, el estrechamiento del MMSE se estima sobre 21 personas y se contradice con su propio Levene ($p = 0,155$), y el 31,1 % está exactamente en el techo. **12.** El punto de operación único sigue sin resolverse. **13.** El título conserva el término normativo, es una afirmación universal sostenida sobre dos cortes en una provincia, y **contradice la propia conclusión de V26**.

MODERADA — Inconsistencias internas verificables

Cantidad	Cuerpo	Suplementario	JSON
n de controles por tramo	74 · 118 · 150	V16: 74 · 216 · 316	74 · 118 · 150
σ del ACE a 0 años	13,2	V16: 12,9	13,183
Percentil del corte 68 sin escolaridad	82	V16: 86	82,0
Youden de la regla vigente	0,549	V17-B: 0,552	0,5487
% señalado en <7, regla vigente	53,7 %	V17-B: 60,3 %	53,7 %

Los bloques V16 y V17-B están calculados sobre conjuntos de controles superados y **el suplemento los sigue enviando**.

Además: el manuscrito afirma que el suplemento contiene las «siete definiciones alternativas» y **no las contiene**; y la cobertura de la clasificación de referencia falta de manera diferencial por escolaridad (92,4 % · 93,9 % · 89,5 %; $p = 0,006$), sin discutirse.

¿Debería dividirse en dos manuscritos?

Sí, y con más razón que en agosto. *Manuscrito A* —listo o casi—: forma funcional, falsación, ausencia de DIF y procedencia documental; no requiere grupo control ni clasificación de referencia y sobrevive intacto. *Manuscrito B* —requiere **rediseño**, no revisión—: la comparación de reglas exige un grupo control definido por referencia independiente del cribado, reclutado en el estrato de baja escolaridad. **Y el bloque V26 no debería ir en ninguno de los dos en su forma actual.**

Lo que el revisor consigna como de primera calidad

La forma funcional · la falsación de la discontinuidad, «el mejor aporte metodológico del trabajo» · la ausencia de sesgo de medición · la reconstrucción documental · y **la honestidad de varios bloques internos**: la detección y corrección del sesgo de Harvey, el registro de los tres hallazgos que obligaron a cambiar conclusiones, el retiro del desenlace de deterioro leve, el abandono del «once veces», y el veredicto de factibilidad de V28 escrito antes de mirar los resultados. *«Ese estándar es superior al de la mayoría de los manuscritos que reviso. El problema no es la voluntad de autocrítica: es que en los tres puntos donde la autocrítica habría desmontado el titular —la definición de control, el nulo de V26 y la armonización del IFS— el proceso se detuvo justo antes.»*

Revisor 3 — *The Lancet / Lancet Regional Health – Americas*

Perfil: salud pública, equidad, generalización y consecuencias para la política sanitaria.

Encuadre del revisor: el trabajo tiene un núcleo excelente envuelto en una afirmación de equidad que, con estos datos, no está identificada. Los tres bloques nuevos no refuerzan la tesis: **la desestabilizan**. En particular, V27b contiene la evidencia más fuerte del repositorio y apunta en una dirección distinta de la que el manuscrito defiende.

FATAL 1 — No se puede separar «efecto de la escolaridad» de «el corte no transporta a San Juan»

- Tramo de 12 o más años de San Juan: $n = 150$, escolaridad **14,7 años**, IFS **22,17**.
- Controles de Torralva 2009 (INECO, Buenos Aires): $n = 26$, escolaridad **14,5 años**, IFS **27,4**.
- A escolaridad prácticamente idéntica, **5,2 puntos de diferencia**.

Dentro de San Juan, todo el gradiente educativo del IFS va de 14,9 a 22,2: **7,3 puntos sobre 10,6 años de escolaridad**. La brecha de sitio a escolaridad constante equivale al **71 % de todo el rango educativo interno de la muestra**. Y San Juan con 14,7 años coincide con los controles chilenos de **11,9 años**: el punto atípico es el grupo de $n = 26$ de un centro terciario porteño del que sale el corte que se aplica en todo el país.

La misma señal está en el ACE-III y el manuscrito no la lee: **la media de los controles con 12 o más años es 85,3 contra un corte de 86**. En el diseño de una puerta las tres tasas son $67,7 \cdot 52,5 \cdot 62,0 \%$: **todos los tramos por encima del 50 %**.

El remate está en `V19_perfil_controles.json`: aplicadas las normas publicadas —ya estratificadas por educación—, el z del IFS es $-1,38 \cdot -1,02 \cdot -1,19$ **por tramo**, $p = 0,166$. La norma educativa borra el gradiente y deja **un corrimiento uniforme de $\approx 1,2$ DE**. Ésa es la descomposición que el manuscrito necesita y no hace.

Consecuencia de política: bajo la lectura del manuscrito, la solución es una corrección continua por escolaridad. Bajo la lectura alternativa, esa corrección es un parche que deja intacto el problema mayor: **ningún corte importado de una muestra metropolitana pequeña sirve en la provincia, a ningún nivel educativo**.

FATAL 2 — El grupo control, con déficit diferencial por escolaridad

(Coincide con el revisor de A&D; se remite a su tabla.) Añade: el gradiente por umbral de reconocimiento es $33,4 \cdot 27,3 \cdot 34,8 \cdot 21,3$ y por peldaño $44,0 \cdot 34,4 \cdot 35,0 \cdot 33,4 \cdot \approx 41,8$. Un rango de 21 a 44 pp **no es independencia de la definición**, contra lo que afirma el manuscrito.

FATAL 3 — La declaración de disponibilidad de código es falsa tal como está escrita

Según el propio `PROCEDENCIA.md`, están sin script **las cinco figuras y las dos tablas del manuscrito enviado**. V25 y V27b leen fuera del árbol del repositorio, y **V28 lee por glob desde `~/Downloads/`**. Once scripts escriben fuera del repositorio.

Sobre ética: **ReDLat es un tercer conjunto de datos**, de un consorcio con su propio IRB, acuerdo de uso y política de publicación. El acta 003/20 cubre las dos cohortes sanjuaninas, no ReDLat.

MAYOR (síntesis)

M1. El «gradiente» es **paridad demográfica**, la métrica de equidad más débil, y V27b la reduce al absurdo: el corte 27,5 alcanza un gradiente de **2,7 pp señalando al 98,5 %**. La métrica tiene óptimos degenerados en ambos extremos y es **probablemente incompatible con la calibración** cuando la prevalencia difiere por estrato. **M2.** Los doce cortes del IFS no son comparables: cuatro provienen de otras condiciones diana. El subconjunto defendible abarca 8 puntos y sigue siendo contundente. **M3.** «3,27 desvíos» usa el denominador más pequeño disponible; en DE propio es 1,47. **M4. La dispersión no replica en el Gran San Juan** (pendiente $-0,0444$, $p = 0,213$, $n = 219$, el 64 % de los controles); el gradiente va de 24,4 a 51,8 pp entre áreas. **M5.** La variable geográfica indexa el **centro de evaluación**, no la residencia, y la ruralidad **se codifica por deducción**. **M6.** La cohorte comunitaria —81 % mujeres, convocatoria voluntaria, sin tasa de participación— no permite hablar de población, y la exclusión fue diferencial. **M7.** La aritmética del flujo no cierra: 109 frente a «los 90 excluidos» frente a 95. **M8.** «Sin costo demostrable» sin margen, y con ventaja de muestra para la regla nueva. **M9.** El cambio mínimo detectable al 95 % es de **22,6 puntos de ACE-III**, y la calculadora ya está publicada mientras el texto dice que no constituye norma. **M10. Ninguna medida de nivel socioeconómico** en un trabajo sobre equidad. **M11.** La compresión se atribuye al techo y **el IFS lo desmiente**: 0 % en el techo y razón de dispersión 2,17 frente a 2,27 del ACE-III.

El mensaje publicable más fuerte, según este revisor

No es «el escalón educativo es inequitativo». Es **el problema de transporte de los puntos de corte**, con el escalón argentino como caso ilustrativo de un artefacto de composición aguas abajo.

En una cohorte comunitaria provincial argentina, **todos** los cortes de cribado en uso clasifican como anormal a una fracción grande de personas sin deterioro **en todos los niveles de escolaridad**: el 86 del ACE-III señala al 43,9 % de los controles con 12 o más años, cuya media (85,3) queda por debajo del propio corte; el 25 del IFS señala al 77,3 % de esas mismas personas y **al 100 % de las que tienen menos de 7 años**. A escolaridad idéntica, el grupo provincial rinde 5,2 puntos menos que los 26 controles porteños de los que salió el corte.

La implicancia no es un escalón mejor ubicado: es que los cortes derivados en muestras de conveniencia de centros metropolitanos requieren datos normativos locales.

Lo que **no** dejaría afirmar en ninguna versión: «una corrección continua elimina el trato desigual sin costo diagnóstico demostrable».

Revisor 4 — *Nature* (Human Behaviour / Medicine / Reviews Neurology)

Perfil: novedad conceptual, rigor metodológico y solidez de las afirmaciones mecanicistas.

Recomendación: rechazo para cualquier revista del grupo *Nature*. El hallazgo central que se presenta como mecanismo es una identidad algebraica, la cantidad que lo cuantifica no está identificada, y el propio repositorio contiene el análisis que lo refuta —sin que aparezca en el manuscrito.

FATAL

F1. La «predicción falsable» no puede fallar. Demostrado por simulación propia bajo cuatro escenarios opuestos (tabla en la sección de verificación de este documento). Las razones son indistinguibles entre el escenario que el manuscrito afirma y su negación exacta. **La prueba no tiene poder discriminante alguno.**

F2. La cifra central (19,1 → 12,0 puntos por unidad de θ) no está identificada. Un modelo de TRI identifica θ sólo hasta transformación monótona. Y no es un tecnicismo: en la métrica de puntaje verdadero de Lord la conclusión se invierte —1,00× instrumento y 1,94× habilidad—. «*Mismo modelo, mismos datos: "la escala explica casi todo" o "la escala no explica nada", según qué reparametrización se privilegie. El manuscrito no discute esta elección; ni siquiera la menciona.*»

F3. El IFS refuta la versión "cerca del techo" del mecanismo — y ese resultado está en el repositorio, ausente del manuscrito. V27 declara por escrito, antes de mirar, que el mecanismo predice **más** compresión cuanto más bajo el techo. El IFS: 0 % en el techo en los tres tramos, y compresión de **2,17×** frente a 2,27× del ACE-III. «*Lo agravante no es el resultado; es su ausencia.*»

F4. Las cifras titulares son extrapolaciones fuera del soporte. Entre los controles hay **cero con 0 años** de escolaridad y **una sola persona con exactamente 20**. El «rendimiento esperado 55,9 puntos con $\sigma = 13,18$ sin escolaridad» que genera el percentil 82 **no tiene ni un solo control detrás.**

MAYOR (síntesis)

M1. «Desaparece» es selección de la prueba que da el nulo buscado: el Levene sobre θ es significativo y la forma es en U. **M2.** La curva característica está mal construida: colapso dirigido por los datos, **remapeo con media no ponderada** en lugar de esperanza condicional, y como síntoma visible $E[ACE|\theta]$ va de 12,6 a 99,0 en vez de 0 a 100. **M3.** La defensa de la contracción del EAP es incompleta, y hay asimetría en el uso de las cifras. **M4.** La descomposición sobreexplica en un 11 % sin declararlo. **M5.** La distinción «no hay sesgo de ítem pero sí no linealidad de escala» **es real y bien conocida**, pero aquí no está establecida: el manuscrito exagera el lado «no hay sesgo», el umbral $\Delta R^2 = 0,035$ es de baja potencia, hay circularidad de identificación, y la no linealidad **se postula, no se establece**. **M6.** Un grupo control del que el 88 % falla otro cribado no es un grupo control, y eso ofrece una explicación alternativa, más simple y no descartada, para **todo el patrón.**

M7 — Novedad: el núcleo mecanicista es psicometría de manual

Afirmación del manuscrito	Origen
El puntaje bruto no es lineal en el rasgo latente; las razones de varianza no son invariantes a transformación monótona	Lord 1953; Lord & Novick 1968
$\sigma_Y \approx g'(\bar{x}) \sigma_X$	método delta; libro de texto
Piso y techo comprimen varianza y curvan asociaciones	psicometría clásica
Ausencia de DIF es compatible con no linealidad de escala	Meredith 1993; Michell 1997; Embretson 1996
Un corte fijo ocupa percentiles distintos si el rasgo se desplaza	consecuencia inmediata

«El aporte del trabajo aquí no es conceptual: es verificar localmente algo que ya se sabía. Para *Nature Human Behaviour* o *Nature Medicine*, esto es descalificante por sí solo.»

Lo que sí es genuinamente valioso y no está siendo el centro del trabajo: la reconstrucción documental · la prueba de placebo, «*aquí sí hay una hipótesis que podía morir y no murió*» · y el cuadro de los doce cortes publicados del IFS, «*más informativo sobre la fragilidad de los cortes fijos que toda la sección de mecanismo, y está sin usar*».

Cómo debería reformularse la afirmación, según este revisor

El ACE-III es una suma ordinal acotada. Su relación con cualquier rasgo latente subyacente es monótona pero no lineal, de modo que **las razones de varianza entre grupos situados en distintos puntos de la escala no son interpretables como diferencias de variabilidad entre personas**. En consecuencia, un umbral fijo ocupa posiciones percentilares distintas según el tramo educativo, y esa consecuencia clínica es válida con independencia de cuál sea la métrica «verdadera». **No estamos en condiciones de determinar qué parte de la compresión corresponde a la escala y qué parte a las personas: esa partición requiere un ancla externa que estos datos no proveen.**

Qué haría falta para publicar en *Nature*

1. Un **ancla externa de habilidad** independiente de los ítems del ACE-III.
2. Una **muestra normativa con soporte real en 0–6 años** de escolaridad y control validado contra referencia independiente.
3. Un **desenlace prospectivo**.
4. **Preinscripción y validación externa**.

¿Alcanzable con estos datos? No. Lo que sí es alcanzable y merece publicarse: el trabajo documental sobre la procedencia del escalón, la prueba de placebo, el gradiente presentado como límite superior, y el cuadro de los doce cortes del IFS. «*Recortar el mecanismo y quedarse con eso mejoraría el trabajo, no lo empobrecería*.»

Anexo — Estado de cada objeción

Ya corregido

Objeción	Corrección
Signo invertido de la desatenuación	Eliminada; sustituida por GRM multigrupo con media y varianza latentes libres
Bootstrap con 40,9 % de recorte	Eliminado
«Predicción falsable» tautológica	Retirada la presentación como predicción; se declara identidad del método delta
Métrica no identificada	Declarado explícitamente, con la comparación en las dos métricas
«Cerca del techo»	Retirado: ningún control está en el techo
Levene sobre θ omitido	Informado en Resultados
Extrapolación a 0 y 20 años	Razones sólo dentro del rango con soporte (4 a 16 años)
Gradiente por máx – mín	Sustituido por el contraste preespecificado , IC 16,7 a 49,7
Bootstrap sin propagar la incertidumbre del modelo	Cada réplica reajusta el modelo normativo
Punto de operación único	Barrido del 10 % al 90 % , con el hallazgo de que un corte único reparte mejor (19,5 frente a 33,4 pp)
Contaminación supuesta y no medida	Medida: la dispersión se atenúa de $-0,082$ a $-0,035$; el gradiente no
Equivalencia a ± 3 sin corrección por familia	Declarada frente a ± 5 ; ± 3 pasa a exploratorio
DTF continuo no informado	Informado: $-0,07$ por año, $p = 4,8 \times 10^{-6}$, 1,2 puntos
Clase de evidencia de la dispersión	Asignada
«Sin costo demostrable»	Sustituido por la lectura correcta del intervalo
Título normativo y afirmación sobre la habilidad	Título descriptivo que declara el diseño
Figuras huérfanas sin script	F11_figuras_instrumento_y_equidad.py
Coeficientes de la calculadora sin script	CALC_coeficientes.py , con verificación contra lo publicado
Mapa de procedencia inexistente	PROCEDENCIA.md , auto-regenerable
PDF suplementario sin figuras	Corregido: las etiquetas se imprimían como texto

Pendiente, y por qué

Objeción	Estado
Armonización del IFS (series motoras, escalas 3 frente a 6)	Decidido hacerlo; hasta entonces V27 no compara cohortes
Bloques V16 y V17-B obsoletos en el suplementario	Requiere depuración del suplemento
Tabla del perfil de controles (V19) ausente del suplemento	Debe incorporarse, con lectura acorde a sus valores p
Frase interpretativa codificada en V19	Debe eliminarse del script
Cifras 60,7 % y 48,9 % de procedencia dudosa	Requiere comprobación dirigida
Aritmética del flujo de participantes (109 / 95 / 90)	Requiere reconciliación
Scripts que escriben fuera del árbol; V28 leyendo de ~/Down loads	Reproducibilidad no resuelta
Gobernanza de ReDLat	Requiere autorización documentada del consorcio si V28 se publica
Medidas de nivel socioeconómico ausentes	No hay datos; limitación declarada
Ancla externa de habilidad	No alcanzable con estos datos
Referencia independiente en baja escolaridad	Requiere reclutamiento nuevo: ReDLat tiene 1 control con CDR = 0 y menos de 7 años
División en dos manuscritos	Decidida; pendiente de ejecución

Nota final

Cuatro revisores independientes, con estándares de cuatro revistas distintas, coincidieron en que el núcleo del trabajo —la procedencia documental del umbral, la forma funcional y su falsación— es sólido y publicable, y en que la capa de equidad no está identificada con estos datos. Tres de los cuatro consignaron explícitamente que el estándar de autocrítica del proyecto es superior al habitual. Uno señaló dónde se detuvo: *«en los tres puntos donde la autocrítica habría desmontado el titular, el proceso se detuvo justo antes»*.

Ese es el valor de esta auditoría, y la razón de conservarla completa.