

MATERIAL SUPLEMENTARIO



Material supplementario

argentinas

Principio de trabajo. Cada bloque se ejecutó sobre los datos originales, sin tomar cifras de corridas anteriores. Cuando un bloque detectó un defecto, se documentó, se corrigió y se reejecutaron todos los bloques dependientes. Tres hallazgos del propio proceso obligaron a modificar conclusiones ya escritas; se detallan más abajo.

37

BLOQUES DE VERIFICACIÓN

TABLES

Bloque	Pregunta	Script	Resultado

Los tres hallazgos que obligaron a cambiar conclusiones

1. La curvatura era en parte un artefacto del techo (V4). El análisis inicial sobre el puntaje bruto daba una razón de cuatro veces entre la pendiente del año 3 y la del año 17. Al reestimar sobre la habilidad latente del modelo de respuesta graduada, persistió dos tercios de la curvatura. El manuscrito reporta la magnitud sobre el puntaje bruto, que es la escala en que se aplica la regla, y declara que un tercio del efecto es atribuible al techo del instrumento.

2. **El desenlace de deterioro leve no era interpretable (V9–V10).** Los controles comunitarios con menos de 7 años de escolaridad puntuaban 66,1, mientras los casos clínicos de deterioro leve del mismo tramo puntuaban 67,9 —siendo 8,6 años mayores—. Dos lecturas competían: contaminación del grupo control, o sobre-aplicación de la etiqueta clínica por efecto del propio corte. Al no poder distinguirlas, el desenlace se eliminó del manuscrito.

3. La razón entre gradientes dejó de reportarse (V11-V13). Las primeras estimaciones expresaban el efecto de equidad como una razón entre el gradiente de la regla vigente y el de la corrección continua. Esa razón resultó inutilizable por dos motivos independientes. Primero, era inestable: pasó de once veces a 1,8 con intervalo que incluía la unidad al emparejar por edad y propagar la incertidumbre. Segundo, y decisivo, **la planitud del gradiente de la corrección continua es una consecuencia algebraica de tipificar respecto de la escolaridad, no un hallazgo:** señalar bajo un cuantil fijo de esa tipificación produce una distribución por consenso. Hoy no se reporta ninguna razón. Se reportan dos cantidades con contenido empírico: el gradiente que produce la regla vigente y si eliminarlo cuesta desempeño diagnóstico.

V1 — Integridad de datos

Ejecutado 2026-07-31. Scripts: `codigo/V1_integridad_datos.py` y `codigo/V1b_fix_dni_y_solape.py`.
Salidas: `resultados/V1_integridad.json`, `resultados/V1b_fix.json`.

Criterio del bloque: reconstruir cada dataset desde el archivo de origen y contrastarlo contra lo que están usando los análisis. Todo lo que no reproduzca se reporta como discrepancia; nada se ajusta en silencio.

Lo que se verificó y reprodujo

Chequeo	Resultado
Flujo de N de la cohorte comunitaria desde el XLSX crudo	867 filas → 866 con edad ≥ 40 → 814 caso completo en los 23 ítems → 776 con educación válida ✓
Ítems fuera de rango antes de corregir	1 caso de <code>ACE_LLectura</code> =2 con máximo 1 → truncado, documentado ✓
Educación implausible (>30 años)	1 caso enmascarado ✓
Regla de puntuación comunitaria del reconocimiento	"reconocimiento ≤ 7 – evocación" se cumple en el 100 % de los casos ✓
Convención de evocación perfecta	38 casos, reconocimiento = 5 en el 100 % ✓
Efecto de la armonización	r con la evocación -0,180 → +0,610 ; r con el resto del test -0,138 → +0,427 ✓
Rango del ítem armonizado y del total	dentro de [0,5] y ≤ 100 ✓
Independencia de observaciones en la clínica	2242 filas = 2242 personas únicas ✓
Suma de los 23 ítems == <code>ACE_total</code> en la clínica	99,63 % — los 8 discordantes son todos <code>solo_total</code> , donde el total proviene del informe y no de los ítems, tal como define la regla de inclusión ✓
Rangos del desenlace y la exposición en la clínica	ACE en [1,100], educación en [0,25], ningún ítem fuera de rango ✓

Veredicto del bloque

Las **dos bases de datos están íntegras**. Todo lo verificable reprodujo: los flujos de N, los rangos, la independencia de observaciones, la reconciliación entre suma de ítems y total, y la regla de puntuación del reconocimiento. En las 626 filas que pudieron parearse de forma no ambigua, el ACE-III y la educación fueron **idénticos** (diferencia máxima 0,0).

Los dos defectos hallados están en el **procesamiento**, no en los datos, y su efecto práctico es acotado. Se documentan igual porque cambian el n final y porque establecen una regla para el resto del estudio.

Defecto 1 (de procesamiento) — El documento pierde el cero a la izquierda al pasar por CSV

Detección. Al parear el dataset comunitario guardado contra la reconstrucción desde el origen, sólo **626 de 762** filas encontraron pareja por documento. Las 136 sin pareja eran exactamente las 136 con documento de 7 dígitos.

Causa. El documento se guardaba como texto conservando el cero inicial (`'0XXXXXXX'`), pero al releer el CSV pandas infiere la columna como entero y lo pierde (`XXXXXXX`). El pareo entre datasets, y con él la exclusión del solapamiento, fallaba para esos casos.

Magnitud real. El **18 %** de los documentos comunitarios tiene cero inicial (157 de 866). Comparando la lista de solapamiento como texto se excluían 15 individuos; comparándola como entero,

1. Efecto práctico: **2 personas que debían excluirse no se excluyeron.**

Corrección. El documento se normaliza a **entero canónico** en todas las fuentes: se eliminan no-dígitos, se descartan longitudes fuera de 6–9 y se convierte a entero, con lo que el cero inicial deja de existir en cualquier representación. Verificado con un ciclo completo de escritura y lectura: 758/758 pareados, diferencia máxima 0,000000.

Los valores en sí nunca estuvieron mal: en las 626 filas comparables el ACE-III y la educación eran idénticos (diferencia máxima 0,0). El defecto era de identificación, no de medición.

Defecto 2 (de procedimiento) — La lista de solapamiento estaba desactualizada

Detección. La lista guardada tenía 17 individuos; contra los datasets definitivos se detectaban 14.

Causa. Se había calculado contra una versión anterior del dataset clínico (2137 personas). El dataset definitivo (2242) cambió de composición al recuperarse casos por la regla de inclusión declarada, de modo que la lista dejó de corresponder.

Corrección. Recalculado entre los datasets definitivos: **18 individuos** presentes en ambas cohortes analíticas. Sólo 10 coincidían con la lista anterior; 8 son nuevos y 7 ya no aplican — diferencia esperable, porque el dataset clínico definitivo recuperó casos que antes no existían.

Verificación de que los 18 son la misma persona (tres criterios independientes del documento, contra la bóveda de identificación de la base clínica):

Criterio	Corroboración
Edad compatible entre ambas evaluaciones (≤ 4 años de diferencia)	18/18
Apellido clínico contenido en el nombre comunitario	17/18
Sexo coincidente	17/18
Los tres criterios simultáneamente	16/18

Los dos casos que fallan un criterio (uno el apellido, otro el sexo) tienen coincidencia exacta o casi exacta de edad y el mismo documento; se interpretan como variantes de carga, no como falsos pareos. Se excluyen igual, por criterio conservador.

Consecuencia. La cohorte comunitaria pasa de 776 a **758** (antes 762). Todos los análisis posteriores se re-ejecutan sobre esta base.

Efecto sobre los resultados

La corrección cambia el n de la cohorte comunitaria en 4 participantes. Los resultados se re-ejecutan íntegramente en el bloque V2; **ninguna cifra publicada debe tomarse de una corrida anterior a esta corrección.**

Regla que queda establecida para el estudio

El documento de identidad se normaliza siempre a entero canónico (`str` $\rightarrow$ sólo dígitos $\rightarrow$ longitud 6–9 $\rightarrow$ entero). Nunca se compara como texto entre datasets, y nunca se guarda de una forma que dependa de conservar ceros a la izquierda.

V2 — Reproducción independiente

Ejecutado 2026-07-31. Script: `codigo/V2_reproduccion_independiente.py` . Salidas: `resultados/V2_reproduccion.json` , `resultados/V2b_testretest.json` , `resultados/V2b_testretest_por_intervalo.json` , log completo en `V2_salida.log` .

Criterio del bloque: recalcular todo desde los datasets corregidos en V1b, sin tomar ninguna cifra de corridas anteriores. **Estas cifras reemplazan a todas las previas.** Ninguna cifra anterior al 2026-07-31 debe usarse en el manuscrito.

Bases: comunitaria n=758, clínica n=2112 (total 2870).

A. Las dos cohortes tienen selección opuesta, como requiere el diseño

	Comunitaria	Clínica
n	758	2112
Mujeres	81,0 %	59,1 %
Edad, mediana [Q1–Q3]	63 [57–69]	73 [66–78]
Educación, mediana [Q1–Q3]	10 [7–15]	12 [8–16]
<7 / 7–11 / ≥12 años	159 / 249 / 350	184 / 606 / 1322
ACE-III, media (DE)	77,6 (13,3)	71,4 (18,7)
ACE-III ≤40	1,6 %	7,5 %

La clínica es 10 años mayor, rinde 6 puntos menos y tiene 5 veces más deterioro grave. Que un resultado se repita en las dos es informativo justamente por eso.

B. Análisis principal — el escalón de 12 años no existe

Indicador de discontinuidad, ajustado por edad, sexo y la forma continua de la educación (HC3):

Cohorte	Escalón	IC 95 %	p
Comunitaria	+0,04 (EE 1,35)	–2,61 a +2,69	0,975
Clínica	+0,13 (EE 1,38)	–2,56 a +2,83	0,924

Prueba de equivalencia (lo que convierte "no encontramos" en "no está"):

	Comunitaria	Clínica
Se descarta un escalón ≥18 puntos	p = 1,3×10 ^{–40}	p = 7,4×10 ^{–39}
Se descarta un escalón ≥5 puntos	p = 0,0001	p = 0,0002

Esto es lo central: no es ausencia de evidencia, es **evidencia de ausencia**. El intervalo de confianza excluye incluso un escalón clínicamente trivial de 5 puntos, en las dos cohortes.

Regresión discontinua local — seis ventanas, ningún resultado significativo, y los signos se contradicen entre cohortes (positivo en la comunitaria, negativo en la clínica):

Ventana	Comunitaria	Clínica
10–13 años	+1,31 [–4,90; +7,52]	–2,50 [–8,67; +3,66]
9–14 años	+1,95 [–2,41; +6,32]	–3,52 [–8,07; +1,03]
8–15 años	+1,54 [–1,96; +5,05]	–0,57 [–4,05; +2,90]

Diferencia cruda 11 vs 12 años: +3,29 [−0,39; +6,98] comunitaria (n=16 vs 112) y +1,82 [−2,32; +5,97] clínica (n=70 vs 447). Aun sin ajustar por nada, la diferencia observada es una fracción del salto de 18 puntos que la regla impone.

C. La forma sí existe, y replica con precisión inusual

	Comunitaria (n=758)	Clínica (n=2112)
Curvatura b_2	−0,0784 [−0,1037; −0,0531]	−0,0784 [−0,1057; −0,0512]
p	$1,3 \times 10^{-9}$	$1,7 \times 10^{-8}$
Cuadrático mejor que lineal	$p = 2,7 \times 10^{-11}$	$p = 3,8 \times 10^{-8}$
Spline mejor que cuadrático	$p = 1,000$	$p = 0,329$

Las dos curvaturas coinciden **hasta el cuarto decimal**. El contraste formal entre cohortes es +0,0064 [−0,0307; +0,0435], $p = 0,735$; la prueba de replicación de la curvatura da $p = 0,764$. Dos cohortes con selección opuesta y 10 años de diferencia de edad producen la misma curva.

Pendiente marginal (puntos de ACE-III por año de educación), comunitaria: 2,92 a los 3 años · 2,30 a los 7 · 1,51 a los 12 · **0,73 a los 17**. Clínica: 3,31 · 2,68 · 1,90 · 1,11. El primer año de escolaridad vale unas **4 veces** lo que el año 17.

El spline natural no mejora al cuadrático en ninguna cohorte: la curva es suave, no tiene codos ni umbrales. **La educación entra al ACE-III de forma continua y con rendimientos decrecientes.**

D. Consecuencia de aplicar la regla vigente

Positividad año por año. El corte cambia de 68 a 86 entre los 11 y los 12 años de escolaridad:

	11 años	12 años	Razón
Comunitaria	6,2 % (1/16)	52,7 % (59/112)	8,4×
Clínica	42,9 % (30/70)	81,2 % (363/447)	1,9×

Por tramo educativo, comunitaria: 56,0 % (<7) · **20,5 % (7–11)** · 40,3 % (≥12). Clínica: 74,5 % · 55,3 % · 61,9 %. En las dos cohortes el tramo 7–11 es el **menos** señalado, pese a ser el de menor reserva cognitiva: la regla invierte el gradiente de riesgo que pretende corregir.

No son sensibilidad ni especificidad. No hay estándar de referencia diagnóstico (ver [README.md](#)). Es la proporción de personas que la regla señala como positivas.

E. Variabilidad test-retest — cuánto es 18 puntos en unidades del instrumento

Subgrupo clínico con evaluaciones repetidas: **218 pares consecutivos de 191 personas**, intervalo mediano 560 días [Q1–Q3 384–850].

	valor
Correlación test-retest	$r = 0,774$
Coefficiente de correlación intraclase	0,727
Cambio medio	-4,22 puntos (DE 11,81)
Error estándar de medición (crudo)	8,35 puntos
Cambio mínimo detectable (95 %)	$\pm 23,1$ puntos

El intervalo largo mezcla error de medición con deterioro real. En una cohorte con enfermedad progresiva, el cambio observado a 2 años no es ruido. Se verificó el gradiente esperado:

Intervalo	n	Cambio medio	DE del cambio	EEM
≤ 180 días	11	+4,64	22,53	15,93
181-365	37	-2,00	8,72	6,17
366-730	97	-4,46	10,53	7,45
>730	73	-6,37	12,02	8,50

El gradiente monótono a partir de los 181 días es exactamente lo que predice la suma "error de medición + deterioro acumulado". El tramo ≤ 180 días es un artefacto de selección: son 11 reevaluaciones clínicamente motivadas, con dos valores extremos (+61 y +29); sin ellos la DE baja de 22,5 a 13,3.

Descomposición formal de la varianza — $\text{Var}(\text{cambio a } t \text{ años}) = 2 \cdot \text{EEM}^2 + t \cdot \text{varianza de la tasa}$, extrapolando a intervalo cero (bootstrap 4000 réplicas):

- **EEM = 8,15 puntos, IC 95 % [1,93; 12,21]** — el intervalo es ancho y así debe declararse
- desviación de la tasa de cambio verdadera = 3,63 puntos/año
- fiabilidad = 0,695

Lo robusto, que no depende del método de estimación (EEM entre 6,2 y 8,4 según se estime):

Cantidad	En unidades de EEM
El escalón que impone la regla (18 puntos)	$\approx 2,2$
La diferencia cruda observada 11 vs 12 años (+3,29)	$\approx 0,4$
El escalón estimado tras ajustar (+0,04)	$\approx 0,005$

La regla impone entre dos evaluaciones un salto mayor que el error de medición del propio instrumento, para corregir una diferencia real que es una fracción de ese error.

Limitación a declarar

El test-retest proviene **sólo de la cohorte clínica** (la comunitaria no tiene reevaluaciones: 0 personas en ambas olas), el intervalo no fue protocolizado, y los 191 sujetos son un subgrupo seleccionado por seguimiento clínico. La estimación sirve para dar **escala** al escalón de 18 puntos, no como norma de fiabilidad del ACE-III en español.

F. Sensibilidades de la curvatura

Especificación	Comunitaria	Clínica
Principal	−0,0784 (n=758)	−0,0784 (n=2112)
Sin armonizar el reconocimiento	−0,0740	—
Columna de total del instrumento	−0,0707	—
Ajustando por ola	−0,0819	—
Excluyendo techo (<95)	−0,0818 (n=726)	−0,0854 (n=2018)
Edad restringida 46–85	−0,0784	−0,0745 (n=2027)
Educación ≤18 años	−0,0710 (n=728)	−0,0583 (n=1992)
Sólo ítems validados	—	−0,0707 (n=2018)

Rango −0,058 a −0,085; el signo y el orden de magnitud no dependen de ninguna decisión analítica. Breusch-Pagan $p = 2,2 \times 10^{-14} \rightarrow$ la varianza no es constante y el uso de errores robustos HC3 en todo el estudio queda justificado empíricamente.

Veredicto del bloque

El análisis principal reproduce íntegramente sobre los datos corregidos. Respecto de las corridas previas a V1b, las cifras cambian en el tercer decimal salvo el escalón comunitario (+0,55 $\rightarrow$ +0,04), que se acerca aún más a cero. La curvatura de la cohorte comunitaria pasó de −0,0835 a −0,0784, con lo que las dos cohortes ahora coinciden hasta el cuarto decimal.

Un defecto de procedimiento hallado y corregido en este bloque: el archivo longitudinal se leía con `dayfirst=True` sobre fechas ISO, lo que invertía día y mes y reducía los pares utilizables de 218 a 33. Corregido a `format="IS08601"`. Es el mismo defecto ya documentado en V1; queda como regla del estudio.

Regla que queda establecida para el estudio

Las fechas se leen siempre con `format="IS08601"` en los archivos derivados (v2 y posteriores) y con `dayfirst=True` sólo en las fuentes v1 con fecha en formato argentino. Nunca se aplica `dayfirst` a una fecha ISO.

Pendiente que este bloque deja abierto

Todos los entregables (`entregable_can/`) todavía contienen cifras anteriores a V1b. Se actualizan después de V5, no antes, para no reescribirlos dos veces.

V3 — Supuestos y especificación

Ejecutado 2026-07-31. Scripts: `codigo/V3_supuestos_especificacion.py` (+ addendum). Salidas: `resultados/V3_supuestos.json`, `resultados/V3b_addendum.json`.

Pregunta del bloque: ¿alguno de los dos resultados —la ausencia de escalón y la curvatura— depende de un supuesto que no se cumple, de una decisión de modelado, o de un puñado de sujetos?

Respuesta: no. Ninguna de las 20 especificaciones alternativas mueve el escalón lejos de cero ni cambia el signo de la curvatura.

A. Residuos y colinealidad

$R^2 = 0,461$ (comunitaria) y $0,305$ (clínica). Los residuos tienen cola izquierda (asimetría $-0,82$ y $-1,32$; Shapiro $p < 10^{-12}$), como corresponde a un test con techo. Breusch-Pagan $p = 2,2 \times 10^{-14}$ (V2). Por eso todo el estudio usa **HC3**, que no supone normalidad ni varianza constante.

El VIF alto del polinomio (14–21) es un artefacto de parametrización, no un problema. Se demostró empíricamente: el coeficiente principal de un polinomio es invariante a trasladar la escala, y al centrar la educación b_2 y su error estándar son **idénticos hasta el sexto decimal** ($-0,078392$, EE $0,012919$ en las dos parametrizaciones). La inferencia sobre la curvatura no está afectada por la correlación entre `edu` y `edu2`.

B. Observaciones influyentes — el resultado no lo produce ningún subgrupo

	Comunitaria	Clínica
Distancia de Cook máxima	0,033	0,029
Casos con Cook > 4/n	51 (6,7 %)	100 (4,7 %)
DFBETA(b_2) máximo	0,309	0,306
b_2 al quitar el 1 % más influyente	$-0,0784 \rightarrow -0,0724$	$-0,0784 \rightarrow -0,0626$
Escalón al quitar el 1 % más influyente	$+0,04 \rightarrow +0,79$	$+0,13 \rightarrow -0,03$

Ningún Cook se acerca a 1. El resultado no depende de observaciones particulares.

C. Especificación alternativa del desenlace

	Comunitaria b_2 / escalón	Clínica b_2 / escalón
Mínimos cuadrados (principal)	$-0,0784$ / $+0,04$	$-0,0784$ / $+0,13$
Robusta de Huber	$-0,0788$ / $+0,69$	$-0,0867$ / $+0,53$
Regresión de la mediana	$-0,0821$ / $+0,65$	$-0,0888$ / $+0,16$
Normal censurada en el techo (100)	$-0,0784$ / $+0,05$	$-0,0779$ / $+0,13$

El techo no distorsiona nada: sólo 0 y 2 personas alcanzan 100 puntos.

D. Especificación alternativa de las covariables

Seis especificaciones (edad lineal, cuadrática, en spline; interacción educación×edad; educación×sexo; sin covariables). **El escalón va de $-0,41$ a $+0,48$ en las 12 combinaciones**, con intervalos que siempre contienen cero; b_2 va de $-0,0742$ a $-0,0814$.

E. Falsación de placebo — el hallazgo más fuerte del bloque

Se estimó el escalón en los 14 cortes candidatos (5 a 18 años de escolaridad). Si el corte de 12 capturara algo real, debería destacarse entre los demás.

Cohorte	Puesto del corte de 12 por magnitud del estadístico	p de permutación entre cortes
Comunitaria	14 de 14 (el último)	1,00
Clínica	12 de 14	0,86

El corte que está en uso clínico es el que menos señal produce de todos los cortes posibles. Ninguno de los 14 sobrevive corrección de Bonferroni ($\alpha = 0,05/14 = 0,0036$) salvo el de 7 años en la clínica.

El corte de 7 años: por qué no contradice el resultado

Único corte con señal (−6,4 puntos, $p < 0,001$; robusto en cuatro ventanas de regresión discontinua local: −6,72, −6,61, −5,43, −6,29). Se descarta como artefacto por tres razones:

1. **Va en sentido contrario.** Los de ≥ 7 años rinden *peor*, lo opuesto a un efecto educativo.
2. **No replica.** En la cohorte comunitaria el mismo contraste da +0,38 [−2,86; +3,62], $p = 0,82$.
3. **Es amontonamiento de credencial.** El 14,6 % de la cohorte clínica declara *exactamente* 7 años ("primaria completa"); las medias crudas clínicas son $6a=62,1 \cdot 7a=58,5 \cdot 8a=60,6$ — un pozo aislado en el valor de amontonamiento, ausente en la comunitaria ($6a=71,1 \cdot 7a=73,5 \cdot 8a=74,3$).

La educación se amontona en los tres valores de credencial (7, 12 y 17 años): 37,5 % de la cohorte comunitaria y 47,3 % de la clínica declara uno de esos tres valores exactos. Esto se declara como limitación de medición de la exposición.

Lectura: el test de placebo es **sensible** —detecta un artefacto de amontonamiento cuando existe— y aun así en 12 años no encuentra nada.

F. Potencia y equivalencia formal

	Comunitaria	Clínica
Error estándar del escalón	1,35	1,38
Diferencia mínima detectable (80 % potencia)	3,79 puntos	3,86 puntos
Potencia para detectar un escalón de 18 puntos	>99,99 %	>99,99 %
Equivalencia dentro de ± 18 puntos (TOST)	$p = 1,3 \times 10^{-40}$	$p = 7,4 \times 10^{-39}$
Equivalencia dentro de ± 5 puntos	$p = 1,2 \times 10^{-4}$	$p = 2,0 \times 10^{-4}$
Equivalencia dentro de ± 3 puntos	$p = 0,014$	$p = 0,019$

El estudio tenía potencia para detectar un escalón cinco veces menor que el que la regla supone. Con dos pruebas unilaterales se concluye equivalencia incluso dentro de un margen de ± 3 puntos.

G. Datos faltantes

De los 866 participantes comunitarios de ≥ 40 años: 758 analizados, 18 excluidos por solapamiento con la cohorte clínica, 90 excluidos por datos faltantes.

Motivo	n
Sin los 23 ítems completos	52
Sin educación válida	43
Con ítems completos Y educación válida	0

Los dos motivos son casi disjuntos (38 tienen ítems pero no educación; 47 al revés), de modo que **ningún excluido es recuperable**: a todos les falta el desenlace o la exposición. No hay análisis de sensibilidad posible por reincorporación.

Los excluidos difieren de los incluidos (a declarar como limitación):

	Incluidos	Excluidos	p
Edad	63,3 (n=758)	64,8 (n=108)	0,100
Educación	10,3	12,0 (n=65)	0,029
ACE-III	75,2	81,4 (n=56)	0,001

Tienen más educación y mejor rendimiento. Como sensibilidad se ponderó por el inverso de la probabilidad de inclusión (modelo logístico sobre edad, sexo y educación): escalón +0,02 [−2,51; +2,56], $b_2 = -0,0707$ ($p = 3,4 \times 10^{-8}$). Ninguna conclusión cambia.

Veredicto del bloque

Los dos resultados sobreviven a todo: 20 especificaciones alternativas, tres estimadores robustos, la eliminación del 1 % más influyente, la ponderación por selección y el test de placebo sobre los 14 cortes candidatos. **La ausencia de escalón en 12 años y la curvatura de la asociación son propiedades de los datos, no de las decisiones de modelado.**

Limitaciones que este bloque incorpora al manuscrito

1. La educación se mide con amontonamiento en valores de credencial (37,5 % y 47,3 % en tres valores) — limitación de medición de la exposición.
2. Los 90 excluidos de la cohorte comunitaria tenían más educación y mejor ACE-III; no son recuperables porque a todos les falta el desenlace o la exposición. La ponderación por probabilidad de inclusión no cambia las conclusiones.
3. Los residuos no son normales (cola izquierda por techo); se usa HC3 en todo el estudio.

V4 — Psicometría y métrica latente

```
Ejecutado 2026-07-31. Script: codigo/V4_tri_dif_metrica_latente.py (+ addenda ordinal y DTF). Salidas: resultados/V4_tri.json , V4b_dif_ordinal.json , V4c_dtf.json .
```

Pregunta del bloque: el puntaje bruto del ACE-III es una función ojival de la habilidad latente y tiene techo, de modo que **comprime en el extremo alto y podría fabricar rendimientos decrecientes donde no los hay**. Es la objeción psicométrica al resultado principal. Se responde reestimando todo sobre θ , métrica de intervalo y sin techo.

Muestra con los 23 ítems completos: comunitaria 758, clínica 2027, combinada 2785.

A. Modelo de respuesta graduada (Samejima), métrica común a las dos cohortes

Discriminación mediana 1,54 (rango 0,82–2,27). Los cinco ítems más discriminativos son recuerdo diferido de nombre y dirección (a=2,27), recuerdo anterógrado (2,08), orientación en espacio (1,91), memoria retrógrada (1,91) y comprensión lectora (1,90).

θ estimado por valor esperado a posteriori con previa normal estándar (implementación explícita, integración sobre grilla de 161 puntos en $[-4, 4]$): media $-0,026$, DE 0,953, error estándar medio 0,271. Correlación con el puntaje bruto $r = 0,980$ (Spearman 0,993).

B. La curvatura sobrevive en la métrica latente

	Curvatura b_2	IC 95 %	p	b_2 estandarizado
Comunitaria, puntaje bruto	$-0,0784$	$-0,1037; -0,0531$	$1,3 \times 10^{-9}$	$-0,00587$
Comunitaria, θ latente	$-0,0031$	$-0,0046; -0,0017$	$3,4 \times 10^{-5}$	$-0,00388$
Clínica, puntaje bruto	$-0,0694$	$-0,0960; -0,0429$	$2,9 \times 10^{-7}$	$-0,00389$
Clínica, θ latente	$-0,0026$	$-0,0040; -0,0012$	$3,6 \times 10^{-4}$	$-0,00262$

El modelo cuadrático sigue superando al lineal sobre θ ($p = 7,3 \times 10^{-6}$ y $5,4 \times 10^{-4}$).

Interpretación honesta: parte de la curvatura sí es artefacto de escala, pero la mayor parte no. En unidades de desviación estándar del desenlace, la curvatura pasa de $-0,00587$ a $-0,00388$ en la comunitaria y de $-0,00389$ a $-0,00262$ en la clínica: sobrevive el 66 % y el 67 % de la curvatura estandarizada, con una concordancia notable entre cohortes. El techo del puntaje bruto exagera los rendimientos decrecientes en aproximadamente un tercio; los otros dos tercios son propiedad de la cognición, no del instrumento.

Pendientes marginales sobre θ (DE de habilidad por año de escolaridad):

	3 años	7 años	12 años	17 años	Razón 3/17
Comunitaria	$+0,157$	$+0,132$	$+0,100$	$+0,069$	2,3×
Clínica	$+0,157$	$+0,136$	$+0,110$	$+0,084$	1,9×

Sobre el puntaje bruto la razón era $\sim 4\times$; sobre θ es $\sim 2\times$. **Se reporta la cifra latente, que es la conservadora.** Que las dos cohortes den $+0,157$ en el año 3 es coincidencia numérica, pero la concordancia del perfil completo no lo es.

C. El escalón en 12 años tampoco existe en la métrica latente

Cohorte	Escalón sobre θ	IC 95 %	p
Comunitaria	$+0,108$	$-0,051; +0,267$	0,184
Clínica	$-0,023$	$-0,162; +0,116$	0,746

D. Funcionamiento diferencial del ítem por educación

Logística ordinal de Zumbo (método primario; la versión binaria es inestable en ítems de piso), con purificación iterativa del anclaje y control de tasa de falso descubrimiento de Benjamini-Hochberg. Grupo focal <12 años n=408; referencia ≥12 años n=350.

Ítem	ΔR^2 Nagelkerke	q (FDR)	Efecto	Dirección
Lectura de palabras irregulares	0,0272	0,0001	despreciable	favorece alta escolaridad
Fluencia semántica	0,0250	<0,0001	despreciable	favorece baja escolaridad
Comprensión lectora	0,0162	0,0001	despreciable	favorece alta escolaridad
Escritura	0,0155	0,0068	despreciable	favorece alta escolaridad
Fluencia fonológica	0,0148	0,0006	despreciable	favorece baja escolaridad
Reconocimiento nombre y dirección	0,0145	0,0047	despreciable	favorece baja escolaridad
Letras fragmentadas	0,0127	0,0432	despreciable	favorece alta escolaridad

Ítems con efecto no trivial ($\Delta R^2 \geq 0,035$): ninguno. Nueve ítems alcanzan significación estadística tras corrección por FDR, todos con efecto despreciable — lo esperable con n=758.

Esto replica el análisis A2 previo (Lectura 0,0264 vs 0,0272 acá; Escritura 0,0171 vs 0,0155), pese a que aquel corrió sobre n=776 sin armonizar el reconocimiento y sin excluir el solapamiento. La conclusión psicométrica es estable frente a esas correcciones.

Los sesgos van en direcciones opuestas y se compensan:

- favorecen **alta** escolaridad (5 ítems): lectura de irregulares, comprensión lectora, escritura, letras fragmentadas, cubo — todos alfabetización o visoconstrucción gráfica ($\Sigma|\Delta R^2| = 0,081$)
- favorecen **baja** escolaridad (4 ítems): fluencia semántica, fluencia fonológica, reconocimiento y recuerdo diferido de nombre y dirección ($\Sigma|\Delta R^2| = 0,060$)

E. Funcionamiento diferencial del TEST COMPLETO — el hallazgo central del bloque

Si los sesgos de ítem se compensan, el puntaje total debería ser insesgado a igual habilidad latente. Se testeó directamente: se modeló el total en función de θ (y θ^2) más la educación.

Cohorte	Baja vs alta escolaridad, a igual θ	IC 95 %	p
Comunitaria	+0,08 puntos	−0,22; +0,38	0,600
Clínica	+0,34 puntos	+0,08; +0,59	0,009

Por año de escolaridad: +0,001 puntos (p = 0,97) en la comunitaria y −0,070 puntos (p < 0,001) en la clínica — es decir, menos de 1 punto acumulado a lo largo de 12 años de escolaridad.

A igual habilidad cognitiva, el ACE-III mide entre 0,08 y 0,34 puntos distinto según la escolaridad. La regla vigente corrige esa diferencia con 18 puntos: entre 50 y 200 veces el sesgo que existe.

El modelo explica el 98,3 % y el 98,5 % de la varianza del total, de modo que la estimación del sesgo residual es precisa.

F. Invarianza entre cohortes

Tres de 23 ítems muestran DIF moderado entre la cohorte comunitaria y la clínica: lectura de palabras irregulares ($\Delta R^2 = 0,050$), letras fragmentadas (0,045) y escritura (0,038) — los mismos ítems de alfabetización. Ninguno alcanza efecto grande.

Consecuencia metodológica: la falta de invarianza estricta justifica la decisión ya tomada de **no reportar nunca una estimación marginal combinada**. El análisis usa un marco único con interacciones cohorte $\times$ educación y presenta las cohortes por separado; la réplica se evalúa como concordancia entre estimaciones independientes, no como precisión de un promedio.

Veredicto del bloque

1. **La curvatura no es un artefacto del techo.** Sobrevive en la métrica latente conservando dos tercios de su magnitud estandarizada, con concordancia entre cohortes. Se reportará sobre θ .
2. **El escalón tampoco aparece sobre θ** en ninguna cohorte.
3. **Los ítems del ACE-III no están sesgados por educación de forma relevante**, y sus sesgos menores se compensan entre sí.
4. **El sesgo educativo del puntaje total, a igual habilidad, es de 0,08 a 0,34 puntos.** La regla lo corrige con 18.

Lo que esto cambia en el mensaje del manuscrito

El problema no está en el instrumento sino en la regla de decisión. El ACE-III es psicométricamente razonable y prácticamente insesgado a nivel del total; lo que produce la inequidad es el ajuste categórico de 18 puntos que se le aplica encima. Esto vuelve el trabajo **constructivo** en lugar de meramente crítico: no propone descartar el ACE-III, propone reemplazar la corrección categórica por una continua.

Pendiente

Reestimar sobre θ las cifras de positividad (bloque V5) y decidir si la figura principal se dibuja sobre puntaje bruto (interpretable clínicamente) o sobre θ (correcto psicométricamente). Propuesta: **bruto en la figura, θ en la tabla de sensibilidades**, declarando la atenuación de $4\times$ a $2\times$.

V6 — Verificación de la codificación diagnóstica

Control	Resultado
Cobertura de la oración canónica	2750 de 3025 conclusiones (90,9 %)
Menciones al ACE-III en la oración clasificatoria	0 de 2750
Menciones a cualquier test o puntaje	0 de 2750
Cobertura por tramo educativo	92,4 % (<7) · 93,9 % (7–11) · 89,5 % (≥ 12); $p = 0,006$
Rotulados sin deterioro con ACE-III <82	1 de 87
Conclusiones con marca «normal» y palabra de severidad	25, clasificadas por severidad (salvaguarda activa)
Validación independiente (ACE-III no usado para clasificar)	92,5 · 78,6 · 54,0; Kruskal-Wallis $p = 1,4 \times 10^{-202}$

La oración canónica es «el presente perfil cognitivo se corresponde con...». Muestra de 50 conclusiones para auditoría humana en `verificacion/V6_muestra_auditoria.csv`.

V10 — Por qué se descartó el criterio funcional

El cuestionario de actividades de la vida diaria presenta gradiente educativo en subescalas específicas:

Subescala	r con escolaridad	¿Usable?
Actividades básicas	+0,010	sí
Manejo de dinero	−0,050	sí
Tareas del hogar	−0,083	sí
Tecnología	−0,154	no
Comunicación (incluye lectura y escritura)	−0,160	no
Transporte y conducción	−0,194	no
Empleo y recreación	−0,265	no

Aun restringido a las tres subescalas neutrales, el criterio funcional no separó a los controles de baja escolaridad de los casos de deterioro leve, con ninguna de cinco definiciones ensayadas. Motivo: el cuestionario está **autoinformado en el 73 %** de los casos.

V12 — Selección del criterio de control

Dependencia educativa de todas las pruebas presentes en ambas bases, ajustada por edad y expresada en desviaciones estándar por año de escolaridad:

Prueba	Efecto por año	Medias por tramo (<7 · 7–11 · ≥12)
Memoria de reconocimiento de lista	0,027	12,2 · 12,2 · 12,8
Series motoras	0,036	2,1 · 2,4 · 2,7
Control inhibitorio motor	0,064	1,3 · 1,7 · 2,2
Dígitos adelante	0,070	4,4 · 4,5 · 5,2
Trail Making B	0,081	173 · 152 · 102
Trail Making A	0,088	80 · 62 · 43
Total del Ineco Frontal Screening	0,111	14,2 · 18,3 · 22,0

Se eligió la **memoria de reconocimiento**: es la menos dependiente de la escolaridad, está en ambas bases con idéntica escala (0–15) y separa monótonamente los grupos clínicos (13,25 sin deterioro · 10,93 deterioro leve · 8,55 deterioro moderado o severo). Las series motoras se descartaron por escalas distintas entre bases (máximo 3 frente a 6). El umbral de 10 puntos es el único en el que la condición de control no depende del tramo educativo (χ^2 $p = 0,198$).

Resultado con ese criterio, superado por V13

Con controles de fuente mixta —comunitarios y clínicos— este bloque estimó un gradiente de la regla vigente de 47,2 puntos porcentuales y una diferencia de Youden de +0,027. **Esas cifras no son las publicadas.** La auditoría externa objetó que la composición del grupo control variaba con la exposición: 0,8 % de controles clínicos en el tramo de menos de 7 años frente al 20,2 % en el de 12 o más, con medias de ACE-III de 65,5 y 93,0 respectivamente. El análisis se rehízo con controles de fuente única; sus resultados son los del bloque siguiente y son los que publica el manuscrito.

V13 — Comparación entre reglas, con controles de fuente única

Procedencia. `codigo/V13_equidad_corregida.py` → `resultados/V13_equidad_corregida.json`. De este bloque provienen las dos cifras titulares del manuscrito. Reemplaza a V12.

Corrige tres defectos señalados por la auditoría externa: los controles pasan a ser de fuente única, se agrega sensibilidad al umbral del criterio, y el efecto deja de expresarse como razón entre gradientes para reportarse como gradiente con su intervalo.

A. Muestra

Casos de deterioro moderado o severo y controles comunitarios, emparejados por edad en estratos quinquenales dentro del rango común.

	Casos	Controles
n	270	270
Edad media, años	69,1	69,0
Con menos de 7 años de escolaridad	—	78
Con 7 a 11 años	—	80
Con 12 años o más	—	112

Punto de operación común a ambas reglas: **66,5 % de positividad**. Es un punto de comparación y no un escenario clínico; iguala la severidad para que la diferencia entre reglas refleje su **forma**.

B. Desempeño y reparto de los señalamientos

Regla	Sensibilidad	Especificidad	Youden	< 7 años	7–11	≥ 12	Gradiente
Vigente 86/68	0,941	0,611	0,552	60,3 %	16,2 %	40,2 %	44,0 pp
Corrección continua	0,952	0,622	0,574	39,7 %	38,8 %	35,7 %	4,0 pp

Las tres columnas por tramo son el porcentaje de personas **sin deterioro** que cada regla señala. El gradiente es la diferencia entre el tramo más señalado y el menos señalado.

Intervalos por remuestreo, 1000 réplicas:

Cantidad	Estimación	IC 95 %	Lectura
Gradiente de la regla vigente	44,0 pp	30,9 a 57,7	empírico
Gradiente residual de la continua	4,0 pp	2,0 a 21,7	esperado por construcción
Diferencia de Youden, continua – vigente	+0,022	–0,022 a +0,074	empírico

Qué es un hallazgo y qué no. La corrección continua tipifica respecto de una media y una varianza estimadas como función de la escolaridad. Señalar bajo un cuantil fijo de esa tipificación produce equidistribución **por construcción**, de modo que el gradiente residual de 4,0 no es un resultado. Las dos cantidades con contenido empírico son el gradiente que produce la regla vigente y el costo diagnóstico de eliminarlo. Su intervalo incluye el cero y excluye pérdidas mayores a 0,022: la conclusión es de **equivalencia**, no de superioridad.

C. Sensibilidad al umbral del criterio de control

El criterio define como control a quien obtiene 10 puntos o más en memoria de reconocimiento de lista. Umbrales más estrictos excluyen más deterioro leve, pero introducen dependencia educativa.

Umbral	n controles	p de asociación con el tramo educativo	Casos leves que califican	Gradiente vigente	Δ Youden
10	270	0,198	72,2 %	44,0 pp	+0,022
11	257	0,024	63,3 %	37,4 pp	+0,031
12	238	0,001	51,2 %	28,9 pp	+0,042
13	210	0,001	36,6 %	28,2 pp	+0,019

El umbral de 10 es el único en que la condición de control **no depende del tramo educativo** ($p = 0,198$). Los más estrictos ganan pureza del grupo control y pierden independencia respecto de la exposición, que es lo que el diseño necesita preservar. **El gradiente de la regla vigente se sostiene entre 28,9 y 44,0 puntos porcentuales en los cuatro umbrales, y la diferencia de Youden entre +0,019 y +0,042:** la conclusión no depende de esta elección.

Limitación principal. Con el umbral empleado, el 72,2 % de los casos clínicos de deterioro leve calificaría como control. Si parte de los controles de baja escolaridad tiene deterioro no detectado, señalarlos no es un falso positivo, de modo que **la contaminación infla el gradiente medido:** los 44 puntos porcentuales son un límite superior.

Reproducción

```
`` codigo/19_build_definitivo.py # corpus clínico -> clinico_definitivo.csv (~25 min)
codigo/20_dx_desde_conclusiones.py # clasificación de referencia desde el texto
codigo/V1b_fix_dni_y_solape.py # normalización de documentos y solapamiento
codigo/V2_reproduccion_independiente.py codigo/V3_supuestos_especificacion.py
codigo/V4_tri_dif_metrica_latente.py codigo/V6_verificacion_dx.py codigo/V12_equidad_definitiva.py
# análisis de equidad + Figura 4 codigo/F1_figuras_manuscrito.py # Figuras 1 a 3
codigo/F3_tablas_manuscrito.py # Tablas 1 a 3 codigo/F4_armar_envio.py # ensamblado y verificación
del reglamento ``
```

Todos los scripts usan rutas absolutas y corren desde cualquier directorio.

V15 — Corrección del sesgo de Harvey en el modelo de dispersión

El defecto

El modelo normativo continuo estima la dispersión con una segunda regresión sobre el logaritmo del residuo al cuadrado. Esa estimación **está sesgada**: si $\varepsilon \sim N(0, \sigma^2)$, entonces

$$E[\log \varepsilon^2] = \log \sigma^2 + E[\log x^2] = \log \sigma^2 - 1,27036$$

de modo que exponenciar la predicción devuelve una varianza multiplicada por $e^{(-1,27036)} = 0,281$, es decir un σ **1,887 veces más chico que el real**.

Cómo se detectó

Revisando por qué el modelo declaraba un percentil 5 que no se comportaba como tal. La comprobación es directa: tipificar los propios controles con el modelo y contar cuántos caen bajo su percentil 5 nominal.

	Sin corregir	Con la corrección
% de controles bajo el percentil 5 nominal	19,0 %	6,5 %
% bajo el percentil 10 nominal	22,8 %	11,9 %
Desvío de los puntajes tipificados (esperado 1,000)	1,906	1,010

El factor 1,906 observado coincide con el 1,887 teórico.

Contraste adicional: el σ modelado tras la corrección reproduce los desvíos residuales observados por tramo educativo, cosa que sin corregir no ocurría ni de lejos.

Tramo	Desvío residual observado	σ modelado corregido
< 7 años	12,39	11,08
7–11 años	8,56	9,26
≥ 12 años	7,42	7,01

Qué cambió y qué no

Cambió todo lo expresado como percentil absoluto. El σ a los 65 años pasa de 6,8 a **12,9** puntos sin escolaridad y de 3,1 a **5,8** con veinte. En consecuencia desaparece el régimen en que el corte de 68 quedaba por debajo del percentil 5 entre los 8 y los 11 años: **el corte cae siempre entre el rendimiento esperado y el percentil 5**. El salto entre 11 y 12 años pasa de $0 \rightarrow 77\%$ a **$5 \rightarrow 65\%$** .

No cambió ninguno de los resultados principales, y la razón es demostrable. Las dos reglas comparadas se calibran con un **cuantil empírico** de la distribución tipificada (`np.quantile(z, positividad)`); multiplicar todos los z por una constante es una transformación monótona creciente, que deja el ordenamiento —y por lo tanto la clasificación— idéntico. Reejecutado V13 completo:

	Antes	Después
Gradiente de la regla vigente	44,0 [30,9; 57,7]	44,0 [30,9; 57,7]
Gradiente residual de la continua	4,0 [2,0; 21,7]	4,0 [2,0; 21,7]
Δ Youden (continua – vigente)	+0,022 [–0,022; +0,074]	+0,022 [–0,022; +0,074]

Tampoco cambian la curva de rendimiento esperado —estimada por una regresión distinta, no afectada—, la pendiente de la escolaridad sobre la log-varianza —un desplazamiento del intercepto no la toca— ni la falsación del escalón.

Calibración residual

Corregida la dispersión, la calibración es adecuada pero no exacta: cae bajo el percentil 5 nominal el 6,5 % en lugar del 5,0 %. Los residuos tipificados conservan asimetría de **–0,58** y curtosis de **+0,43**, atribuibles al techo del instrumento. Por eso los percentiles próximos a los extremos deben leerse como aproximaciones, y así se declara en las limitaciones del manuscrito.

Implementación: la constante figura como `SESG0_LOGCHI2` en `codigo/F6_figura_equipo.py`, `V8_correccion_continua.py`, `V12_equidad_definitiva.py` y `V13_equidad_corregida.py`, y ya está incorporada al intercepto publicado en `resultados/CALC_coeficientes.json`.

V16 — Magnitud de la heterocedasticidad

La variabilidad del rendimiento entre personas sin deterioro **no es constante a lo largo de la escolaridad**, y ese es el motivo estructural por el que ningún corte fijo puede funcionar.

Tramo	n	Media del ACE-III	Desvío
< 7 años	131	65,5	13,82
7–11 años	216	76,3	8,58
≥ 12 años	316	86,0	7,77

Prueba de Levene entre los tres tramos: $W = 32,97$; $p = 2,2 \times 10^{-14}$.

Modelada de forma continua, $\log(\sigma^2) \sim \text{escolaridad} + \text{edad}$ sobre los controles comunitarios:

Término	Coefficiente	IC 95 %	p
Escolaridad	−0,0806	−0,1132 a −0,0480	$1,5 \times 10^{-6}$
Edad	+0,0082	−0,0120 a +0,0285	0,430

A los 65 años el desvío pasa de **12,9 puntos** sin escolaridad a **5,8** con veinte: se reduce a menos de la mitad. De ahí que un mismo número ocupe percentiles muy distintos según a quién se aplique.

Escolaridad	0	4	8	11	12	16	20
Corte vigente	68	68	68	68	86	86	86
Percentil que ocupa	86	56	20	5	65	42	28

V17 — Material trasladado desde el cuerpo del manuscrito

Por límite de extensión, el detalle de estos análisis se reporta aquí. Ninguno fue eliminado.

A. Robustez, especificación completa

Distancia de Cook máxima 0,033 y 0,029; al eliminar el 1 % más influyente la curvatura pasó de $-0,0784$ a $-0,0724$ y $-0,0626$. Las regresiones robusta de Huber, de la mediana y censurada en el techo coincidieron. En **doce especificaciones de covariables** la discontinuidad osciló entre $-0,41$ y $+0,48$, siempre con intervalos que contienen el cero, y la ponderación por probabilidad de inclusión arrojó $+0,02$. En **ocho especificaciones alternativas** la curvatura osciló entre $-0,058$ y $-0,085$.

B. Cortes empíricos exploratorios

Los cortes que maximizan el índice de Youden en la muestra emparejada resultaron **más bajos que los vigentes en los tres tramos, y graduados**: 57, 64 y 78, frente a 68, 68 y 86. Están sesgados por el diseño de dos puertas y por optimismo no corregido —no hay validación externa ni corrección por remuestreo—, de modo que **no constituyen una recomendación clínica** y se reportan sólo para mostrar la dirección del desajuste. La comparación que sí tiene contenido es que la regla vigente supera a cualquier corte único: Youden 0,552, frente a 0,497 con corte 82 y 0,394 con corte 86.

C. Por qué el criterio funcional no era utilizable

El cuestionario de actividades de la vida diaria está autoinformado en el **73 %** de los casos, y sus subescalas de empleo, comunicación y tecnología presentan gradiente educativo (r hasta **$-0,265$**): incluyen ítems de lectura, escritura y uso de tecnología que penalizan la falta de exposición y no el deterioro. Definir controles con ese instrumento habría fabricado el resultado, porque el criterio de control habría heredado la propia exposición bajo estudio.

D. Métrica latente, detalle

Unidimensionalidad esencial: razón entre autovalores 5,75; primer componente 35,8 %. Independencia local: Q3 medio $-0,035$, con 2 de 253 pares por encima de 0,20, estructuralmente esperables. Curvatura sobre la habilidad latente: $-0,0031$ y $-0,0026$ ($p = 3,4 \times 10^{-5}$ y $3,6 \times 10^{-4}$), que conservan el 66 % y el 67 % de la magnitud observada en la escala bruta. Curvatura por estrato de gravedad: $-0,0655$, $-0,0609$ y $-0,0696$; interacción $p = 0,961$.

E. Funcionamiento diferencial por ítem

Ver los bloques V4-D y V4-E de este suplemento, que reportan el barrido completo en ambas cohortes con ΔR^2 de Nagelkerke, q corregido por tasa de falso descubrimiento, delta de Mantel-Haenszel y clase ETS.